СКОРОСТЬ И СОБЛЮДЕНИЕ ИНСТРУКЦИЙ ЛОКАЛЬНЫМИ ЯЗЫКОВЫМИ МОДЕЛЯМИ КЛАССА 3B НА GPU С 4 ГБ ПАМЯТИ

Иванова В. П., Минчук С. В.
Белорусский государственный университет
Минск, Республика Беларусь
E-mail: vip42696@gmail.com, stasminchuk0@gmail.com

Научный руководитель: Лукашевич М. М.

Сравнены квантованные Llama 3.2 3B и Qwen 2.5 3B на NVIDIA GeForce GTX 1650. Выполнено 490 запросов для оценки качества, скорости и холодного запуска. В прогретом режиме декодирование занимало около 30 мс на токен. При температуре 0 доля строгого выполнения требований составила 20,0% у Llama и 33,3% у Qwen. Выявлены расхождения между лексическим сходством с эталоном, соблюдением формата и корректностью кода.

Введение

При локальном запуске языковой модели с ограниченной видеопамятью важны задержка ответа и выполнение прикладных требований. В работе [1] сравнивались средства запуска LLM. Здесь при одинаковых оборудовании и программной среде исследуются Llama 3.2 3B Instruct и Qwen 2.5 3B Instruct.

Цель – сопоставить быстродействие и соблюдение инструкций на русскоязычных заданиях. BLEU и ROUGE дополнены проверками формата ответа, структуры JSON и поведения сгенерированных функций.

I. Методика эксперимента

Стенд включает NVIDIA GeForce GTX 1650 с 4096 МиБ видеопамяти, Linux, Python 3.12.14 и Ollama 0.35.0. Обе модели имеют квантование Q4_K_M. Использован нативный потоковый API Ollama; число выходных токенов и серверное время декодирования получены из полей eval_count и eval_duration без приближённого подсчёта. Код, настройки и результаты сохранены в проекте [2].

Набор содержит 30 заданий: по три на факты, суммаризацию, перевод, логику, извлечение данных, Python-код, операционные системы, JSON, объяснения и алгоритмы. Для каждой модели выполнены три повтора при температурах 0 и 0,7 – всего 360 ответов. Рабочий контекст равен 2048 токенам, лимит ответа – 384. Зафиксированы seed 1729–1731, top_p = 1, top_k = 0 и repeat_penalty = 1. Порядок моделей между повторами менялся, задания перемешивались; перед блоком выполнялся отдельный прогрев.

Автоматически проверялись 15 заданий на факты, логику, извлечение, JSON и код. Точные ответы сравнивались целиком после удаления краевых пробелов и приведения регистра. Для JSON проверялись отсутствие пояснений, ключи, типы и значения; для кода – требование «только функция» и тесты в изолированном Docker-контейнере. Успех означал выполнение всех проверок. Смысловое качество открытых ответов автоматически не оценивалось.

BLEU [3] вычислялся отдельно для каждого ответа со сглаживанием; в табл. 2 приведено среднее таких оценок, а не корпусный BLEU. ROUGE-L [4] рассчитывался как F1 с Unicode-разбиением на слова. Для разницы долей успеха построен 95%-й bootstrap-интервал по 15 задачам (2000 выборок); повторы сначала усреднялись внутри задачи.

II. Быстродействие и память

В серии скорости варьировались контекст (2048 и 4096), объём входа (1, 8 и 24 одинаковых предложения) и лимит выхода (64 и 256 токенов). Пять повторов каждой комбинации для двух моделей дали 120 запросов. TTFT измерялось на клиенте до первого текстового фрагмента; серверное время на токен определялось как

$$\tau = \frac{D_{\text{eval}}}{N_{\text{eval}}}. \tag{1}$$

В (1) D_{eval} – серверная длительность генерации, N_{eval} – число выходных токенов. Это среднее серверное время, а не замер интервалов между приходами токенов.

Таблица 1 – Среднее TTFT: контекст 2048, лимит 64 токена, пять повторов

Вход, токены	Llama, с	Qwen, с
81 / 92	0,300	0,356
256 / 316	0,704	1,155
656 / 828	2,113	2,678

В первом столбце табл. 1 приведены длины одного и того же текста в токенизаторах Llama и Qwen соответственно. Поэтому различия TTFT отражают также различия токенизации. В серии скорости средние τ по отдельным условиям лежали в диапазонах 30,04–31,25 мс для Llama и 29,51–30,29 мс для Qwen. Это соответствует примерно 32–34 токенам/с; оснований объявлять модели одинаковыми по всем показателям нет.

По данным /api/ps модели размещались в GPU при обоих размерах контекста. При 2048 токенах объём размещения составлял около 2,16 ГиБ для Llama и 1,94 ГиБ для Qwen, при 4096 – 2,38 и 2,01 ГиБ. Эти значения относятся к модели по данным API, а не ко всей занятой видеопамяти системы.

Отдельная серия включала по пять запросов после выгрузки каждой модели. Среднее время загрузки составило 6,60 с для Llama и 5,65 с для Qwen; TTFT – 7,07 и 6,16 с. Дисковый кэш ОС не очищался. Холодный старт не объединялся с прогретыми измерениями. В прогретых сериях фиксировалось повторное использование кэша входного контекста, поэтому TTFT нельзя интерпретировать как время обработки полностью нового входа.

III. Качество и выполнение требований

Все 490 основных запросов завершились без ошибок API. В серии качества восемь ответов достигли лимита длины; эти случаи сохранены. Результаты сведены в табл. 2. Доля успеха рассчитана по 45 ответам на 15 проверяемых заданий для каждой модели и температуры; ROUGE и BLEU – по всем 90 ответам соответствующей группы.

Таблица 2 – Лексические оценки и выполнение требований

Модель	t	BLEU	R-L, %	Успех, %
Llama	0	28,79	45,70	20,0
Qwen	0	34,84	47,20	33,3
Llama	0,7	26,33	43,15	20,0
Qwen	0,7	35,40	48,34	35,6

При $t = 0$ преимущество Qwen по доле успеха составляет 13,3 процентного пункта, но 95%-й интервал разницы равен $[-13{,}3; 40{,}0]$ п. п. При $t = 0{,}7$ разница составляет 15,6 п. п., интервал – $[-8{,}9; 42{,}2]$. Оба интервала включают ноль. Наблюдаемое различие не подтверждает общего превосходства на малом диагностическом наборе.

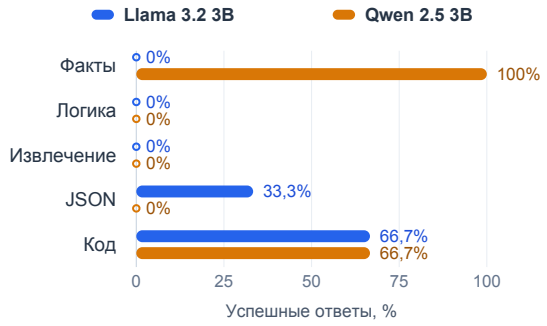


Рис. 1 – Строгое выполнение требований при $t = 0$; по три задания и три повтора в категории

Рис. 1 раскрывает причину низкой итоговой доли успеха. В фактологических заданиях Llama часто добавляла точку или пояснение вместо требуемого одиночного значения. При извлечении данных модели меняли разделители, добавляли слова или конечную точку. Такие ответы отклонялись по формату, даже если часть фактов была верна; показатель не следует трактовать как долю только фактологических ошибок.

В JSON у Qwen средний ROUGE-L при $t = 0$ достиг 91,40%, но ни один из девяти ответов не прошёл полную проверку: модель добавляла Markdown-ограждения, а в части случаев пропускала поле. У Llama прошли три ответа из девяти. Следовательно, близость к эталону не заменяет проверку структуры и инструкции «только JSON».

Функциональные тесты прошли шесть из девяти программ у каждой модели при каждой температуре. Обе модели справились с факториалом и бинарным поиском, но при проверке палиндрома удаляли пунктуацию вопреки условию сохранять её. Этот пример показывает, почему распространённое решение похожей задачи нельзя автоматически считать правильным для заданной спецификации.

Заключение

Обе модели обеспечили локальный инференс на GPU с 4 ГБ памяти при контекстах до 4096 токенов. Прогретое декодирование занимало около 30 мс на токен; холодный старт добавлял несколько секунд загрузки. Средние лексические оценки и доля выполнения требований у Qwen выше, но неопределённость сравнения велика. Выбор модели требует совместной оценки задержек, формата и правильности ответов. Независимая человеческая оценка открытых заданий ещё не выполнена.

1. Дичковский, В. А. Оценка производительности программ для локального запуска больших языковых моделей / В. А. Дичковский, М. В. Ковалёв // Информационные технологии и системы 2025. – Минск : БГУИР, 2025. – С. 49–50.

2. Bleu: a Method for Automatic Evaluation of Machine Translation / K. Papineni [et al.] // Proc. of ACL. – 2002. – P. 311–318. – DOI: 10.3115/1073083.1073135.

3. Lin, C.-Y. ROUGE: A Package for Automatic Evaluation of Summaries / C.-Y. Lin // Text Summarization Branches Out. – 2004. – P. 74–81.